Comparação entre ResNet50 e EfficientNet-B0 na Classificação de Lesões Dentárias em Radiografias Panorâmicas por *Transfer Learning*

Eduardo Jesus Dal Pizzol
FGA0261 — Inteligência Artificial II
Universidade de Brasília (UnB)
Brasília, Brasil
Matrícula: 251008114

Matheus Lemes Amaral
FGA0261 — Inteligência Artificial II
Universidade de Brasília (UnB)
Brasília, Brasil
Matrícula: 241031852

***Resumo*—A interpretação de radiografias panorâmicas para cárie e lesão periapical é trabalhosa e varia entre examinadores. Este trabalho compara ResNet50 e EfficientNet-B0, pré-treinadas no ImageNet e ajustadas por *fine-tuning*, na classificação multirrótulo do tipo de lesão (cárie, cárie profunda e lesão periapical) em 2.996 recortes de dentes do conjunto público DENTEX, com protocolo idêntico, três sementes e divisão por radiografia. No teste (107 radiografias, 432 dentes), as redes tiveram discriminação equivalente: AUC macro de 0,856 e 0,855 e F1 macro de 0,693 e 0,677, com diferença pareada de −0,016 (IC 95% [−0,065; 0,028]). A EfficientNet-B0, com cerca de seis vezes menos parâmetros, obteve menor perda logarítmica (0,362 contra 0,417; IC da diferença [0,020; 0,092]). A lesão periapical teve AUC acima de 0,90, mas, com apenas 23 casos no teste e sem validação externa, os resultados são exploratórios e não indicam uso clínico.**

***Palavras-chave*—aprendizado profundo, *transfer learning*, radiografia panorâmica, cárie dentária, lesão periapical.**

I. Introdução

Cárie e lesão periapical estão entre os achados mais frequentes em radiografias odontológicas. A radiografia panorâmica mostra toda a arcada em uma única imagem, mas com sobreposição de estruturas e menor detalhe local, e sua interpretação depende da experiência do examinador. Redes neurais convolucionais (CNNs) já foram aplicadas à detecção de cárie [5] e de lesões apicais [6], e podem apoiar a triagem ao sinalizar dentes suspeitos para revisão, sem substituir o diagnóstico.

Boa parte desses estudos usa bases privadas, o que dificulta reproduzir e comparar resultados. Conjuntos públicos como o DENTEX [7] e o Tufts Dental Database [9] reduziram essa barreira, mas comparações entre arquiteturas costumam relatar uma única execução, sem incerteza, e usar a acurácia, que é enganosa quando as classes são desbalanceadas.

Este trabalho compara uma arquitetura residual clássica e maior, a ResNet50 [1], com uma compacta, a EfficientNet-B0 [2], sob protocolo idêntico, no DENTEX, com rótulo por dente e incerteza estimada por *bootstrap*. São investigadas três questões de pesquisa:

- **QP1:** há diferença de discriminação (AUC, F1 macro) entre as duas arquiteturas no mesmo protocolo?
- **QP2:** a comparação se mantém ao considerar calibração (NLL, ECE) e ponto de operação (limiar)?
- **QP3:** quais conclusões resistem às limitações do conjunto (poucas lesões periapicais, rótulos multirrótulo, fonte única)?

A Seção II apresenta a fundamentação; a III, a metodologia; a IV, os resultados; a V, a discussão e as ameaças à validade; e a VI conclui.

II. Fundamentação e Trabalhos Relacionados

No *transfer learning*, uma rede pré-treinada em uma base grande, como o ImageNet [3], é reaproveitada em outra tarefa. As primeiras camadas aprendem filtros genéricos, como bordas e texturas, e as últimas, padrões específicos da tarefa original [4]; por isso, o *fine-tuning* costuma funcionar com poucos dados médicos.

A ResNet [1] introduziu conexões residuais, em que cada bloco aprende uma correção $F(x)$ somada à entrada x, o que permite treinar redes profundas sem degradação. A ResNet50 tem 50 camadas em blocos de gargalo e, com a cabeça de três saídas usada aqui, 23,5M de parâmetros. A EfficientNet [2] escala profundidade, largura e resolução em proporção fixa a partir de uma arquitetura base encontrada por busca, com blocos MBConv e atenção por canal; a versão B0 tem 4,0M de parâmetros nesta configuração.

Com classes desbalanceadas, a acurácia favorece a classe majoritária. Usam-se, por classe, sensibilidade, especificidade, F1 e AUC, que independe do limiar. A perda logarítmica (NLL) e o erro esperado de calibração (ECE) avaliam se as probabilidades refletem a frequência real de acertos [13].

Lee *et al.* [5] ajustaram uma CNN pré-treinada para detectar cárie em radiografias periapicais, e Ekert *et al.* [6] detectaram lesões apicais em panorâmicas. O DENTEX [7] propõe detecção de dentes anormais com numeração e diagnóstico, tendo como referência um detector hierárquico baseado em difusão [8]; bases como a Tufts [9] e a PRAD-10K [10] ampliam os dados disponíveis. Diferentemente desses trabalhos, este estudo não propõe um detector: isola a etapa de classificação para comparar dois *backbones* com incerteza quantificada.

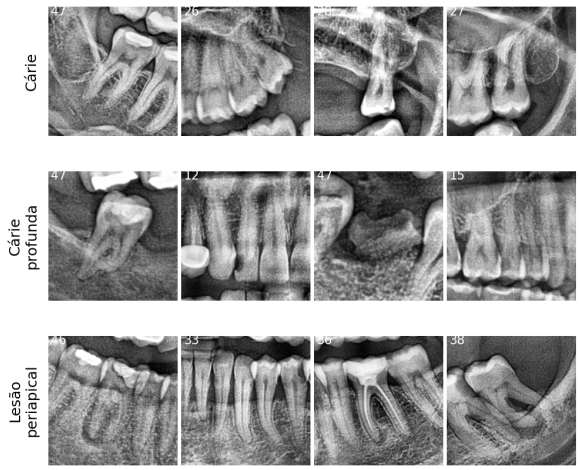


Figura 1. Exemplos de recortes de treino por classe; o número é o dente (notação FDI).

III. Metodologia

A. Dados e rótulos

Utilizou-se o subconjunto totalmente anotado do DENTEX [7]: radiografias panorâmicas de pacientes com 12 anos ou mais, de três instituições com equipamentos distintos, sob licença CC BY-NC-SA 4.0. Cada anotação traz a caixa do dente, sua numeração FDI e um diagnóstico entre cárie, cárie profunda, lesão periapical e dente impactado. Foram reunidas as 705 radiografias de treino e as 50 de validação do desafio, únicas com rótulos no mesmo formato; o teste do desafio usa outro esquema de rótulos e não foi empregado.

A unidade de análise é o dente. Como um dente pode ter mais de um diagnóstico (por exemplo, cárie profunda e lesão periapical), a tarefa foi formulada como multirrótulo com três saídas. Dentes impactados foram excluídos, por se tratar de condição de posição e não de lesão; as radiografias que só os continham saíram da amostra, restando 707 radiografias e 2.996 dentes. O DENTEX anota apenas dentes anormais; assim, o modelo distingue o *tipo* de lesão, e o negativo de uma classe é um dente com outra lesão, não um dente saudável.

B. Pré-processamento e divisão

Cada dente foi recortado por uma janela quadrada centrada em sua caixa, com lado igual à maior dimensão acrescida de 15% por lado, redimensionada para 224×224 pixels e equalizada por CLAHE [11] (Fig. 1). A janela quadrada evita bordas artificiais de preenchimento, que variariam com o formato do dente e poderiam servir de atalho. A divisão 70/15/15 foi feita por radiografia, para que dentes de um mesmo exame não ficassem em conjuntos diferentes, e estratificada pela presença de lesão periapical, a classe mais rara (Tabela I). O aumento de dados foi aplicado só no treino, sem espelhamento vertical, que inverteria a arcada.

Tabela I
Protocolo experimental.

Aspecto	Configuração
Dados	DENTEX [7]; panorâmicas de três instituições; CC BY-NC-SA 4.0
Amostra	707 radiografias e 2.996 dentes (treino/validação/teste: 494/106/107 radiografias; 2.092/472/432 dentes)
Rótulos	Multirrótulo por dente: cárie, cárie profunda, lesão periapical; impactados excluídos
Divisão	70/15/15 por radiografia, estratificada por lesão periapical (semente 42)
Entrada	Janela quadrada centrada no dente (margem de 15% por lado), 224×224, CLAHE (limite 2,0; blocos 8×8)
Aumento (treino)	Rotação $\pm 10^{\circ}$, translação 5%, escala 0,9–1,1, espelhamento horizontal, brilho e contraste $\pm 20\%$
Modelos	ResNet50 (23,5M parâmetros; pesos ImageNet V2) e EfficientNet-B0 (4,0M; pesos ImageNet V1), via torchvision [15]; cabeça com 3 saídas
Perda	Entropia cruzada binária com peso $\sqrt{N_{neg}/N_{pos}}$ (0,57; 1,95; 4,07)
Otimização	AdamW [12], decaimento 10^{-4}; taxa 10^{-4} (base) e 10^{-3} (cabeça); cosseno; lote 32; precisão mista
Treino	Até 30 épocas; parada antecipada (paciência 6) por F1 macro de validação; sementes 42, 43 e 44; GPU T4
Limiar	Um por classe, maximizando o F1 na validação
Incerteza	*Bootstrap* por radiografia (2.000 repetições), IC de 95% [14]

C. Modelos e treinamento

As duas redes foram carregadas do torchvision com pesos do ImageNet, e a última camada foi substituída por uma camada linear de três saídas (*logits*), com a sigmoide aplicada dentro da perda. Toda a rede foi ajustada, com taxa de aprendizado dez vezes maior na camada nova, que parte de pesos aleatórios. O peso positivo da perda usou a raiz quadrada da razão entre negativos e positivos, pois o valor cheio (16,6 para lesão periapical) tende a desestabilizar o treino. A parada antecipada usou o F1 macro de validação, menos sensível que a acurácia à classe majoritária. Hiperparâmetros, época e limiares foram definidos sem acesso ao teste, avaliado uma única vez ao final.

D. Avaliação e inferência

Para cada classe, calcularam-se sensibilidade, especificidade, F1 e AUC contra as demais, além de médias macro, NLL (entropia cruzada binária média) e ECE com 15 faixas [13]. Os resultados de cada arquitetura são a média das três sementes; como a divisão é fixa, o desvio entre sementes reflete só inicialização e ordem dos lotes. A incerteza amostral foi estimada por *bootstrap* sobre radiografias, em que todos os dentes de um exame entram ou saem juntos [14]. A comparação entre redes é pareada: em cada repetição, ambas são avaliadas nas mesmas radiografias. Os valores de p são exploratórios, sem correção para comparações múltiplas. Código, divisão e predições estão em https://github.com/Edupizzol/odonto-cnn.

Tabela II
TESTE: MÉDIA ± DESVIO ENTRE TRÊS SEMENTES [IC 95% POR *bootstrap*] E DIFERENÇA PAREADA.

Métrica	Trivial[a]	EfficientNet-B0	ResNet50	ResNet50 − EfficientNet-B0 [IC 95%]	p
F1 macro	0,425	0,693 ± 0,034 [0,626; 0,739]	0,677 ± 0,016 [0,604; 0,731]	−0,016 [−0,065; 0,028]	0,470
AUC macro	0,500	0,856 ± 0,005 [0,811; 0,893]	0,855 ± 0,013 [0,818; 0,887]	−0,001 [−0,023; 0,022]	0,942
NLL	–	0,362 ± 0,055 [0,283; 0,450]	0,417 ± 0,040 [0,325; 0,519]	0,054 [0,020; 0,092]	0,003
ECE	–	0,074 ± 0,003 [0,064; 0,099]	0,087 ± 0,006 [0,075; 0,113]	0,013 [0,000; 0,026]	0,047
F1 cárie	0,889	0,909 ± 0,005 [0,884; 0,932]	0,914 ± 0,005 [0,892; 0,933]	0,005 [−0,008; 0,019]	0,415
Especificidade cárie	0,000	0,275 ± 0,123 [0,183; 0,359]	0,430 ± 0,070 [0,320; 0,538]	0,155 [0,092; 0,225]	0,001
F1 cárie profunda	0,286	0,509 ± 0,018 [0,388; 0,616]	0,532 ± 0,035 [0,403; 0,641]	0,023 [−0,048; 0,076]	0,474
Sensibilidade cárie profunda	1,000	0,606 ± 0,090 [0,484; 0,721]	0,546 ± 0,029 [0,403; 0,667]	−0,060 [−0,142; 0,004]	0,074
F1 lesão periapical	0,101	0,663 ± 0,087 [0,480; 0,794]	0,586 ± 0,078 [0,372; 0,748]	−0,077 [−0,203; 0,040]	0,200
Sensibilidade lesão periapical	1,000	0,609 ± 0,087 [0,417; 0,765]	0,551 ± 0,126 [0,333; 0,741]	−0,058 [−0,183; 0,077]	0,431
AUC lesão periapical	0,500	0,910 ± 0,018 [0,823; 0,974]	0,921 ± 0,015 [0,856; 0,970]	0,011 [−0,025; 0,061]	0,630

[a] Prever todas as classes como positivas. Prevalência no teste: cárie 80%, cárie profunda 17%, lesão periapical 5%.

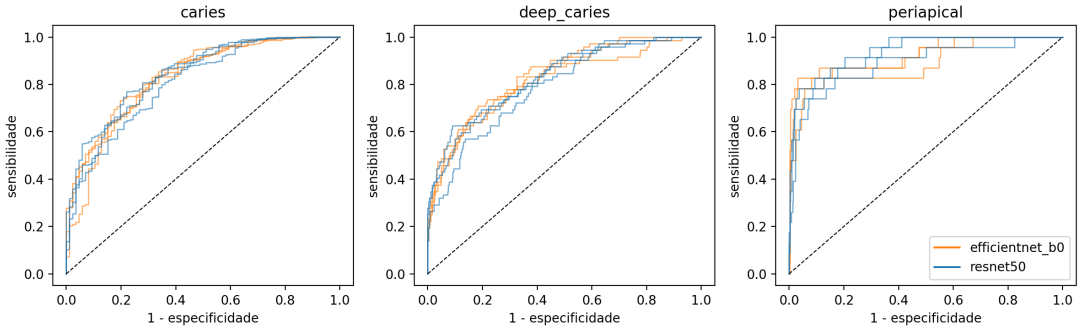


Figura 2. Curvas ROC por classe no teste (uma curva por semente).

Tabela III
LESÃO PERIAPICAL (LP) POR ARCADA NO TESTE (n: DENTES).

			EfficientNet-B0		ResNet50	
Arcada	n	LP	Sens. [IC 95%]	Espec.	Sens. [IC 95%]	Espec.
Superior	197	4	0,25 [0,00; 1,00]	0,993	0,17 [0,00; 0,67]	0,986
Inferior	235	19	0,68 [0,48; 0,83]	0,981	0,63 [0,41; 0,80]	0,978

Tabela IV
RESULTADOS POR EXECUÇÃO. C: CÁRIE; CP: CÁRIE PROFUNDA.

		F1 macro			Limiares
Modelo	Sem.	Val. (0,5)	Teste (0,5)	Teste (aj.)	C/CP/LP
EfficientNet-B0	42	0,665	0,695	0,730	0,48/0,06/0,61
	43	0,643	0,663	0,663	0,07/0,18/0,64
	44	0,627	0,695	0,688	0,09/0,29/0,71
ResNet50	42	0,672	0,657	0,664	0,50/0,24/0,42
	43	0,731	0,646	0,695	0,11/0,30/0,34
	44	0,735	0,655	0,673	0,27/0,21/0,72

Tabela V
MATRIZES DE CONFUSÃO MÉDIAS NO TESTE (TRÊS SEMENTES).

Classe	Modelo	VN	FP	FN	VP
Cárie	EfficientNet-B0	23,7	62,3	6,0	340,0
	ResNet50	37,0	49,0	13,7	332,3
Cárie profunda	EfficientNet-B0	303,3	56,7	28,3	43,7
	ResNet50	323,0	37,0	32,7	39,3
Lesão periapical	EfficientNet-B0	403,7	5,3	9,0	14,0
	ResNet50	401,7	7,3	10,3	12,7

Tabela VI
EFEITO DO LIMIAR NO TESTE (MÉDIA DAS SEMENTES).

			Cárie		C. prof.	L. periap.
Limiar	Modelo	F1 macro	Sens.	Espec.	Sens.	Sens.
Ajustado	EfficientNet-B0	0,693	0,983	0,275	0,606	0,609
	ResNet50	0,677	0,961	0,430	0,546	0,551
Fixo 0,5	EfficientNet-B0	0,684	0,925	0,488	0,431	0,696
	ResNet50	0,653	0,923	0,477	0,444	0,507

IV. RESULTADOS

A. Desempenho no conjunto de teste

A Tabela II resume o teste (107 radiografias, 432 dentes). As redes superaram com folga a referência trivial nas classes minoritárias (F1 de 0,51–0,53 em cárie profunda e 0,59–0,66 em lesão periapical, contra 0,29 e 0,10), mas em cárie o ganho foi pequeno (0,909–0,914 contra 0,889), pois essa classe ocupa 80% dos dentes. A discriminação foi praticamente idêntica: AUC macro de 0,856 e 0,855, com diferença pareada de −0,001 (IC 95% [−0,023; 0,022]). A diferença de F1 macro, −0,016, também tem intervalo que inclui zero, e as curvas ROC das seis execuções se sobrepõem em todas as

classes (Fig. 2). A lesão periapical teve a maior AUC (0,910 e 0,921), mas, com 23 casos, seus intervalos passam de 0,1 de largura. Por arcada (Tabela III), 19 casos são inferiores, e os 4 superiores não permitem estimativa.

Na validação, com limiar 0,5, a ResNet50 havia obtido F1 macro maior (0,713 $\pm$ 0,035 contra 0,645 $\pm$ 0,019); no teste, com o mesmo limiar, a ordem se inverteu (Tabela IV). Como o melhor *checkpoint* é o máximo entre cerca de 20 épocas, medido em apenas 25 lesões periapicais, a validação é otimista e serviu apenas para seleção.

B. Calibração e ponto de operação

A diferença mais nítida foi de calibração: a NLL da EfficientNet-B0 foi menor (0,362 contra 0,417; diferença de 0,054, IC [0,020; 0,092]), e o ECE seguiu a mesma direção, com intervalo que toca zero. Os pontos de operação também diferiram: a ResNet50 foi mais específica em cárie (0,430 contra 0,275), e a EfficientNet-B0, mais sensível em cárie profunda (0,606 contra 0,546; Tabela V). Isso decorre sobretudo dos limiares: o de cárie variou de 0,07 a 0,50 entre execuções (Tabela IV), pois maximizar o F1 de uma classe com 80% de prevalência favorece prever quase tudo como positivo. Com limiar fixo em 0,5 (análise *post hoc*, Tabela VI), as especificidades de cárie se igualaram, e a vantagem da EfficientNet-B0 em cárie profunda desapareceu.

V. Discussão e Ameaças à Validade

Para a QP1, não há evidência de diferença de discriminação entre as arquiteturas neste protocolo: as AUCs coincidem, e as diferenças de F1 estão dentro do ruído amostral. Como a EfficientNet-B0 tem cerca de seis vezes menos parâmetros (4,0M contra 23,5M), ela entrega o mesmo desempenho com menor custo, o que importa quando os dados são escassos.

Para a QP2, a comparação depende do critério. A EfficientNet-B0 teve menor NLL, a diferença mais consistente observada, enquanto as diferenças de sensibilidade e especificidade refletem sobretudo limiares instáveis. Comparar redes por um único ponto de operação, escolhido em uma validação pequena, pode sugerir vantagens inexistentes.

Para a QP3, resistem a equivalência em AUC e a vantagem da EfficientNet-B0 em NLL; a lesão periapical é promissora (AUC acima de 0,90), mas se apoia em 23 casos.

Validade interna e estatística. Três sementes com divisão fixa medem só a variação de inicialização, e o *bootstrap* condiciona nos modelos treinados, sem capturar outras divisões. O limiar por F1 favoreceu prever cárie; outro critério, como o índice de Youden, não foi testado para não escolher o método após ver o teste. Cerca de 20 comparações foram feitas sem correção, então valores de p isolados próximos de 0,05 não confirmam diferenças.

Validade de construção. Sem classe saudável, a especificidade mede a separação entre tipos de lesão, não entre lesão e dente sadio. A janela inclui dentes vizinhos, mas o rótulo é só do dente central. No treino, a lesão periapical foi mais frequente em dentes inferiores (7,9% contra 3,3%), o que abre um possível atalho posicional, não verificável com 4 casos superiores no teste. O peso de classe na perda desloca as probabilidades das classes raras e afeta a calibração.

Validade externa. Os dados vêm de três instituições, apenas panorâmicas e pacientes a partir de 12 anos, sem validação externa. O sistema pressupõe o dente já localizado e numerado, o que exigiria uma etapa de detecção na prática. Os resultados não indicam uso clínico; no máximo, apoio à triagem após validação prospectiva.

VI. Conclusão

Este trabalho comparou ResNet50 e EfficientNet-B0 na classificação multirrótulo de cárie, cárie profunda e lesão periapical em recortes de dentes do DENTEX, com protocolo idêntico, três sementes e incerteza por *bootstrap*. As redes tiveram discriminação equivalente (AUC macro de 0,856 e 0,855), e a EfficientNet-B0, seis vezes menor, apresentou melhor perda logarítmica. As diferenças de sensibilidade e especificidade dependeram mais do limiar do que da arquitetura. Trabalhos futuros devem incluir dentes saudáveis rotulados, validação externa, validação cruzada agrupada por radiografia e critérios de limiar definidos de antemão.

Referências

[1] K. He, X. Zhang, S. Ren and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE CVPR*, 2016, pp. 770–778.

[2] M. Tan and Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proc. ICML*, 2019, pp. 6105–6114.

[3] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li and L. Fei-Fei, "ImageNet: A large-scale hierarchical image database," in *Proc. IEEE CVPR*, 2009, pp. 248–255.

[4] J. Yosinski, J. Clune, Y. Bengio and H. Lipson, "How transferable are features in deep neural networks?" in *Advances in NeurIPS*, vol. 27, 2014, pp. 3320–3328.

[5] J.-H. Lee, D.-H. Kim, S.-N. Jeong and S.-H. Choi, "Detection and diagnosis of dental caries using a deep learning-based convolutional neural network algorithm," *J. Dent.*, vol. 77, pp. 106–111, 2018.

[6] T. Ekert *et al.*, "Deep learning for the radiographic detection of apical lesions," *J. Endod.*, vol. 45, no. 7, pp. 917–922, 2019.

[7] I. E. Hamamci *et al.*, "DENTEX: An abnormal tooth detection with dental enumeration and diagnosis benchmark for panoramic X-rays," arXiv:2305.19112, 2023.

[8] I. E. Hamamci *et al.*, "Diffusion-based hierarchical multi-label object detection to analyze panoramic dental X-rays," in *Proc. MICCAI*, 2023, pp. 389–399.

[9] K. Panetta, R. Rajendran, A. Ramesh, S. P. Rao and S. Agaian, "Tufts Dental Database: A multimodal panoramic X-ray dataset for benchmarking diagnostic systems," *IEEE J. Biomed. Health Inform.*, 2022.

[10] Z. Zhou, Y. Zhang, R. Xu, X. Zhao and T. Li, "PRAD: Periapical radiograph analysis dataset and benchmark model development," arXiv:2504.07760, 2025.

[11] K. Zuiderveld, "Contrast limited adaptive histogram equalization," in *Graphics Gems IV*, P. S. Heckbert, Ed. Academic Press, 1994, pp. 474–485.

[12] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *Proc. ICLR*, 2019.

[13] C. Guo, G. Pleiss, Y. Sun and K. Q. Weinberger, "On calibration of modern neural networks," in *Proc. ICML*, 2017, pp. 1321–1330.

[14] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. Chapman & Hall, 1993.

[15] A. Paszke *et al.*, "PyTorch: An imperative style, high-performance deep learning library," in *Advances in NeurIPS*, vol. 32, 2019, pp. 8024–8035.